

Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ «НАЦИОНАЛЬНЫЙ
ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО»
(УНИВЕРСИТЕТ ИТМО)

УДК: 004.932

СТАТЬЯ

по теме:

СРАВНИТЕЛЬНЫЙ АНАЛИЗ АРХИТЕКТУР ПАМЯТИ МАМБА-2,
TRANSFORMER И GRU ДЛЯ RL-АГЕНТОВ В СРЕДЕ VIZDOOM

Автор,
Студент направления
09.03.03

подпись, дата

Федорин К.В.

Исполнитель НИР,
Студент

подпись, дата

Федорин К.В.

Санкт-Петербург 2025

РЕФЕРАТ

Отчёт 10 с., 2 рис., 3 табл., 9 ист.

ОБУЧЕНИЕ С ПОДКРЕПЛЕНИЕМ, MAMBA-2, VIZDOOM, АРХИТЕКТУРЫ
ПАМЯТИ, TRANSFORMER, GRU, PPO

В работе проведено эмпирическое сравнение четырёх архитектур обработки последовательностей — GRU, Transformer, Mamba-2 и Perceiver IO — интегрированных в фреймворк Sample Factory на основе алгоритма PPO для задачи визуальной навигации в частично наблюдаемой среде ViZDoom. Эксперименты выполнены на GPU NVIDIA RTX 5090 с полным обучением до 500 млн шагов. Результаты показывают, что Mamba-2 демонстрирует наилучший баланс между скоростью обучения, финальной производительностью агента и вычислительной эффективностью: финальный reward 1310 при латентности инференса 1,5 мс и пиковом потреблении VRAM 5,2 ГБ.

ВВЕДЕНИЕ

Задача визуальной навигации в условиях частичной наблюдаемости остаётся одной из ключевых проблем при разработке интеллектуальных агентов для сложных динамических сред. В отличие от классических задач обучения с подкреплением, где агент имеет доступ к полному состоянию среды, визуальная навигация предполагает принятие решений исключительно на основе потока пикселей без доступа к координатам, карте или полной информации о мире.

Среда ViZDoom, представляющая собой API к игре DOOM, широко применяется как эталонная платформа для таких исследований благодаря контролируемости, воспроизводимости и достаточной сложности задач при относительно низких требованиях к ресурсам [1]. Среда остаётся актуальным бенчмарком: в недавних работах 2023–2025 годов авторы продолжают использовать ViZDoom для оценки новых RL-архитектур [2]. В данной работе исследуется, как различные архитектуры памяти влияют на способность агента обучаться в подобных условиях.

Актуальность исследования определяется появлением в 2024–2025 годах новых подходов к обработке последовательностей. В частности, модели на основе пространств состояний (State Space Models), такие как Mamba-2 [3,4], предлагают альтернативу доминирующим трансформерным архитектурам [5], сочетая линейную вычислительную сложность рекуррентных сетей с возможностью моделирования длинных зависимостей. Согласно обзору [6], SSM-архитектуры демонстрируют конкурентоспособность с трансформерами при значительно меньших требованиях к ресурсам.

Цель работы — экспериментальное сравнение архитектур памяти GRU, Transformer, Mamba-2 и Perceiver IO для RL-агентов в среде ViZDoom по метрикам скорости обучения, финальной производительности, латентности инференса и стабильности.

1 Обзор архитектур

В рамках исследования рассмотрены три класса архитектур памяти. Рекуррентные нейронные сети, в частности GRU [7], обрабатывают последовательность пошагово, сохраняя внутреннее состояние. Их главный недостаток — проблема затухания градиента, затрудняющая запоминание длинных зависимостей. Трансформеры с механизмом внимания стали доминирующей архитектурой в обработке последовательностей, однако квадратичная вычислительная сложность по длине последовательности делает их ресурсоёмкими. Модели на основе пространств состояний, к которым относится Mamba-2 [3,4], представляют собой новый класс архитектур. Селективный механизм Mamba позволяет модели динамически фокусироваться на релевантной информации из прошлого, сочетая линейную сложность RNN с эффективностью трансформеров. Perceiver IO использует архитектуру с латентными токенами, которые служат буфером состояния переменной длины.

2 Методология

В качестве базового фреймворка выбран Sample Factory — высокопроизводительная реализация алгоритма PPO, поддерживающая работу с частично наблюдаемыми средами. Алгоритм PPO [8] предпочтён альтернативам благодаря стабильности обучения и умеренным требованиям к памяти по сравнению с SAC [9]. Кроме того, будучи online-методом, PPO не требует предварительной генерации демонстраций, в отличие от Decision Mamba.

Таблица 1 — Сравнение RL-алгоритмов

Алгоритм	PPO	SAC	DM
Тип обучения	Из текущего опыта	Из буфера памяти	Моделирование опыта
Стабильность	Высокая	Средняя	Высокая
Память (VRAM)	Умеренная	Высокая	Низкая

Среда ViZDoom настроена в режиме случайной генерации уровней с размерностью визуального входа 64×64 пикселя в градациях серого. Пространство действий включает 7 дискретных действий. Все модули памяти реализованы с сохранением 512-мерного скрытого состояния для обеспечения сопоставимости результатов.

Каждый эксперимент включает два этапа: пилотное обучение на 10 млн шагов для быстрой отбраковки нестабильных конфигураций и полное обучение на 500 млн шагов. Все запуски проведены с тремя разными seed для оценки статистической значимости. Оборудование: GPU NVIDIA RTX 5090 (24 ГБ GDDR7), процессор AMD Ryzen 9 7950X, 64 ГБ ОЗУ.

3 Результаты экспериментов

На этапе пилотного обучения выявлена значительная разница в скорости сходимости архитектур. Mamba-2 и GRU демонстрируют монотонный рост cumulative reward, тогда как Perceiver IO и Transformer показывают нестабильное обучение с выраженными колебаниями (рисунок 1).

На рисунке 1 показана динамика обучения на пилотном этапе, а на рисунке 2 — прогресс полного обучения.




Рисунок 1 — Результаты обучения: слева — пилотный этап (10 млн шагов), справа — полный цикл (до 500 млн шагов). Mamba-2 превосходит остальные архитектуры по стабильности и финальному reward

Рисунок 2 —

Таблица 2 — Сводные метрики архитектур после 500 млн шагов обучения

Архитектура	Reward (mean ± std)	Инференс, мс	VRAM пик, ГБ	Шагов до сходимости
GRU (baseline)	1240 ± 85	1,2	4,1	180M

Архитектура	Reward (mean ± std)	Инференс, мс	VRAM пик, ГБ	Шагов до сходимости
Transformer	1180 ± 142	3,8	7,6	320M
Mamba-2	1310 ± 68	1,5	5,2	150M
Perceiver IO	1095 ± 198	4,1	8,3	>500M

Mamba-2 демонстрирует наилучший результат по финальному reward и скорости сходимости при умеренном потреблении ресурсов. Прирост относительно базовой модели GRU составляет около 5,6% по reward при увеличении латентности инференса всего на 0,3 мс. Трансформерная архитектура уступает по всем метрикам, требуя втрое больше времени на инференс и вдвое больше VRAM.

Perceiver IO показывает наименьшую стабильность обучения — стандартное отклонение между seed составляет почти 200 единиц reward. Вероятная причина — недостаточная пропускная способность между входным пространством и латентным буфером при выбранной размерности $n_latents = 64$.

Отдельный эксперимент проведён для сравнения версий Mamba между собой и с GRU.

Таблица 3 — Детальное сравнение версий Mamba с GRU

Метрика	GRU	Mamba-1	Mamba-2
Reward (mean)	1240	1265	1310
Reward (std)	85	79	68
Инференс, мс	1,2	1,4	1,5
VRAM, ГБ	4,1	4,8	5,2
FPS обучения	28400	25100	24300

Переход от Mamba-1 к Mamba-2 даёт прирост в финальной производительности примерно на 3,5% при сопоставимой скорости инференса. При этом стабильность обучения также улучшается: стандартное отклонение снижается с 79 до 68.

4 Обсуждение

Полученные результаты показывают, что селективный механизм Mamba-2 обеспечивает эффективное запоминание релевантных паттернов из прошлого при меньших вычислительных затратах по сравнению с механизмом внимания в трансформерах. GRU остаётся конкурентоспособным baseline, особенно с учётом минимальных требований к ресурсам. Трансформерная архитектура, доминирующая во многих областях машинного обучения, не показала преимуществ в данной задаче — квадратичная сложность само внимания ограничивает эффективную длину контекста для real-time взаимодействия со средой. Аналогичные трудности с трансформерами в RL-задачах отмечены в работе [2].

ЗАКЛЮЧЕНИЕ

В ходе работы проведено эмпирическое сравнение четырёх архитектур памяти для RL-агентов в среде ViZDoom. Архитектура Mamba-2 продемонстрировала наилучший баланс между производительностью и эффективностью: финальный reward 1310 при латентности инференса 1,5 мс и пиковом потреблении VRAM 5,2 ГБ. Это на 5,6% превосходит базовую модель GRU при умеренном увеличении ресурсных затрат.

Сформулированы практические рекомендации: для задач с ограниченным бюджетом на инференс рекомендуется использовать Mamba-2 с параметром `d_state = 16`; GRU остаётся предпочтительным выбором при жёстких ограничениях по памяти; трансформерные архитектуры целесообразны при приоритете точности над скоростью и наличии достаточных вычислительных ресурсов.

Полученные результаты подтверждают, что селективные модели пространств состояний представляют собой перспективное направление для задач визуальной навигации в частично наблюдаемых средах.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Kempka M. и др. ViZDoom: A Doom-based AI Research Platform for Visual Reinforcement Learning // Computational Intelligence and Games (CIG). 2016.
2. Cherepanov E. и др. Recurrent Action Transformer with Memory // arXiv preprint arXiv:2306.09459. 2023.
3. Gu A., Dao T. Mamba: Linear-Time Sequence Modeling with Selective State Spaces // International Conference on Learning Representations (ICLR). 2024.
4. Dao T., Gu A. Transformers are SSMs: Generalized Models and Efficient Algorithms Through Structured State Space Duality // International Conference on Machine Learning (ICML). 2024.
5. Vaswani A. и др. Attention Is All You Need // Advances in Neural Information Processing Systems (NeurIPS). 2017. Т. 30.
6. Qu H. и др. A Survey of Mamba // ACM Transactions on Intelligent Systems and Technology. 2024.
7. Chung J. и др. Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling // arXiv preprint arXiv:1412.3555. 2014.
8. Schulman J. и др. Proximal Policy Optimization Algorithms // arXiv preprint arXiv:1707.06347. 2017.
9. Haarnoja T. и др. Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor // International Conference on Machine Learning (ICML). 2018. Сс. 1861–1871.