

Министерство науки и высшего образования Российской Федерации

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ

ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ

«Национальный исследовательский университет ИТМО» (Университет ИТМО)

Факультет: Факультета прикладной информатики

Образовательная программа:

Программирование в инфокоммуникационных системах

Направление подготовки: 09.03.03

Прикладная информатика

ОТЧЁТ

по производственной практики (научно-исследовательской работы)

Тема: Расширение экспериментальной базы сравнения GRU
и Mamba-2 в on-policy RL: длительные запуски (250М шагов),
вариация контекста (32–128 кадров)
и повышение статистической значимости (20+ seed)

Выполнил: Федорин К.В.

Научный руководитель: Гусарова Н. Ф.

СОДЕРЖАНИЕ

Введение	3
1 Инструктаж по работе с программным обеспечением	4
2 Длительный прогон Mamba-2 (250М шагов)	5
3 Вариация контекстного окна (32, 64, 128)	6
4 Повышение статистической значимости (20+ seed)	8
5 Анализ и оформление результатов	12
Заключение	13
Список использованных источников	14

ВВЕДЕНИЕ

Отчёт составлен по результатам производственной практики (научно-исследовательской работы) по направлению 09.03.03 «Прикладная информатика».

До практики были выполнены пробные запуски на 50М шагов. Их результатов не хватало для уверенных выводов по Mamba-2 на больших бюджетах, по влиянию окна контекста и по разбросу между сидами. В ходе практики были проведены запуски Mamba-2 на 250М шагов, исследованы окна 32/64/128, набрано 20+ сидов на архитектуру, и выполнено итоговое сравнение шести архитектур.

Все запуски делались на одном GPU (NVIDIA RTX 5090 Laptop, 24 ГБ) через Sample-Factory и APPO [1]. Среда — ViZDoom [2].

1 Инструктаж по работе с программным обеспечением

На первом этапе было изучено программное обеспечение, используемое в работе: — Sample-Factory [1] — фреймворк для on-policy RL с GPU-векторизацией и распределённым обучением; — ViZDoom [2] — интерфейс для взаимодействия со средой Doom; — nvidia-smi, Nsight Systems — инструменты профилирования GPU; — bash-скрипты и YAML-конфигурации для управления экспериментами.

В ходе инструктажа были освоены:

- запуск тренировочного цикла APPO с различными архитектурами памяти;
- сбор метрик (reward, loss, FPS, использование памяти) через встроенную систему логирования Sample-Factory;
- конфигурирование гиперпараметров через аргументы командной строки;
- возобновление прерванных экспериментов (resume).

Были выполнены пробные запуски для проверки работоспособности всех компонентов.

2 Длительный прогон Mamba-2 (250М шагов)

Ранее Mamba-2 была протестирована на бюджете 50М шагов: средняя награда 14.45, стандартное отклонение 2.25 (4 сйда). Один из сидов (seed3) достиг 17.81 — уровня GRU Optimized, остальные три находились в диапазоне 13.0–13.5.


Было решено увеличить бюджет в 5 раз — до 250М шагов. Результаты приведены в таблице 1.

Таблица 1 — Сравнение Mamba-2 при бюджетах 50М и 250М шагов

Бюджет	Средняя награда	Стд. откл.
50М НРО	14.45	2.25
250М	17.48	2.02

Средняя награда увеличилась с 14.45 до 17.48 (+21%) при незначительном снижении дисперсии (2.25 → 2.02). При бюджете 250М шагов Mamba-2 достигла уровня GRU Optimized (15.76). По-видимому, прирост награды Mamba-2 продолжается и после 50М шагов, тогда как GRU выходит на плато раньше.

Таблица 2 — Кривые обучения Mamba-2 при бюджетах 50М и 250М шагов



3 Вариация контекстного окна (32, 64, 128)

Было исследовано влияние размера контекстного окна (backpropagation window / recurrence) на качество обучения GRU. Использованы две конфигурации: GRU Baseline (стандартные гиперпараметры) и GRU Optimized (HPO: adamw, lr=4.05e-4, exploration_loss_coeff=0.00202, weight_decay=0.00196).

Результаты представлены в таблице 2.

Таблица 3 — Влияние размера контекстного окна на GRU Baseline и GRU Optimized

Размер окна	GRU Baseline	GRU Optimized
w32	13.10 ± 0.39	15.88 ± 0.45
w64	13.38 ± 0.66	15.46 ± 0.27
w128	13.16 ± 0.40	15.95 ± 1.57

Было установлено, что размер окна не оказывает значимого влияния на результат: значения w32 и w128 практически идентичны как для Baseline (13.10 vs 13.16), так и для Optimized (15.88 vs 15.95). Оптимизация гиперпараметров даёт устойчивый прирост +2.5–2.8 независимо от размера окна.

Более высокая дисперсия GRU Optimized при w128 (1.57 против 0.45 у Baseline) объясняется меньшим числом запусков (3 сйда против 9) и, вероятно, является артефактом ограниченной выборки.

Таблица 4 — Сравнение GRU при различных размерах контекстного окна

GRU: влияние размера окна rollout/recurrence (3 сета на конфигурацию, 50M)





Таблица 5 — Индивидуальные траектории GRU (все запуски, все окна)



4 Повышение статистической значимости (20+ seed)


Было выполнено 9+ сидов для каждой архитектуры: GRU Baseline — 9, GRU Optimized — 9, GLA — 10, DeltaNet — 10. С учётом ранее полученных данных (Mamba-2 HPO — 4, Mamba-1 — 3) общее число запусков превысило 45.

Итоговый рейтинг архитектур представлен в таблице 3.

Таблица 6 — Итоговый рейтинг архитектур по средней награде

#	Архитектура	Среднее	Std	Сидов	Коэф. вариации
1	GRU Optimized	15.76	0.86	9	5.5%
2	Mamba-2 HPO Best	14.45	2.25	4	15.6%
3	GRU Baseline	13.21	0.45	9	3.4%
4	Mamba-1	9.03	3.15	3	34.9%
5	GLA	6.57	2.60	10	39.6%
6	DeltaNet	4.17	2.24	10	53.7%

Таблица 7 — Сравнение временных рядов обучения всех архитектур



GRU Optimized занял первое место со средним значением 15.76 ± 0.86 . Коэффициент вариации 5.5% свидетельствует о высокой стабильности обучения. Mamba-2 находится на втором месте, уступая GRU Optimized 8%

при 50M шагах; дисперсия Mamba-2 примерно втрое выше (15.6% против 5.5%).

GRU Baseline (13.21) с коэффициентом вариации 3.4% является самой стабильной архитектурой, превосходя все SSM, кроме Mamba-2.

GLA и DeltaNet демонстрируют неприемлемо высокий разброс результатов (39.6% и 53.7%). Значительная часть сидов застревает на уровне 2.0–4.0, что близко к случайному поведению, и эти архитектуры не могут быть рекомендованы для on-policy RL на данном масштабе.

Таблица 8 — Scatter-график всех запусков: распределение финальных наград




Таблица 9 — Рейтинг архитектур с указанием средних и разброса

Итоговый рейтинг архитектур (50 млн шагов среды, VizDoom RL)

#	Архитектура	Среднее	Std	Сидов	Мин	Макс
1	GRU Optimized	15.76	0.86	9	14.63	17.68
2	Mamba-2 HPO	14.45	2.25	4	13.03	17.81
3	GRU Baseline	13.21	0.45	9	12.68	14.00
4	Mamba-1	9.03	3.15	3	5.66	11.89
5	GLA	6.57	2.60	10	2.52	10.37
6	DeltaNet	4.17	2.24	10	1.52	7.72

Поименные результаты по сидам для каждой архитектуры приведены ниже.

Таблица 10 — Mamba-2 HPO: результаты по сидам

Сид	Награда
seed1	13.45
seed2	13.49
seed3	17.81
seed4	13.03

Таблица 11 — Mamba-1: результаты по сидам

Сид	Награда
seed1	11.89
seed2	9.53
seed3	5.66

Таблица 12 — GLA: результаты по сидам

Сид	Награда
seed1	8.76
seed2	7.75
seed3	2.97
seed4	10.37
seed5	7.39
seed6	3.96
seed7	6.39
seed8	7.48
seed9	8.13
seed10	2.52

Таблица 13 — DeltaNet: результаты по сидам

Сид	Награда
seed1	7.46
seed2	5.22

Сид	Награда
seed3	2.48
seed4	2.00
seed5	2.01
seed6	4.18
seed7	3.79
seed8	5.27
seed9	1.52
seed10	7.72

Таблица 14 — GRU Baseline: влияние окна и сйда

Сид	w32	w64	w128
seed1	13.47	14.00	13.02
seed2	12.69	12.68	13.61
seed3	13.15	13.45	12.85

5 Анализ и оформление результатов

На заключительном этапе был проведён анализ полученных данных.

Основные выводы:

1. *GRU с HPO обеспечивает наилучший результат при 50М шагах.*

Средняя награда составила 15.76 ± 0.86 . Даже базовая GRU (13.21 ± 0.45) превосходит все SSM, за исключением Mamba-2.

2. *Mamba-2 — лучшая среди SSM, но требует больше данных.*

При 50М шагах отставание от GRU Optimized составляет 8%. При увеличении бюджета до 250М достигнуто значение 17.48, что соответствует уровню GRU Optimized.

3. *Размер контекстного окна не влияет на результат.*

Окна 32, 64 и 128 кадров показывают практически идентичные средние для обеих конфигураций GRU.

4. *GLA и DeltaNet не подходят для on-policy RL на данном масштабе.*

Коэффициент вариации 40–54% против 3–5% у GRU. 7 из 10 сидов DeltaNet не превышают награды 5.0 — уровень, близкий к случайному поведению.

5. *GRU характеризуется наибольшей стабильностью.*

Коэффициент вариации 3.4% (Baseline) и 5.5% (Optimized) значительно ниже, чем у любой SSM, что снижает риск неудачных запусков.

ЗАКЛЮЧЕНИЕ

В ходе производственной практики был получен обширный экспериментальный материал по сравнению GRU и Mamba-2 в задаче on-policy RL на среде VizDoom.

Были выполнены следующие задачи:

— проведён длительный запуск Mamba-2 (250M шагов), показавший прирост +21% относительно базового бюджета 50M; — исследовано влияние размера контекстного окна (32, 64, 128) — значимого влияния не обнаружено; — выполнено 45+ запусков с 9+ сидами для каждой архитектуры, что обеспечило статистическую значимость результатов; — проведён сравнительный анализ 6 архитектур (GRU, Mamba-2, Mamba-1, GLA, DeltaNet), подтвердивший преимущество GRU с HPO при ограниченном бюджете шагов.

Полученные данные будут использованы в выпускной квалификационной работе для обоснования выбора архитектуры памяти нейросетевого агента.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Petrenko A. и др. Sample Factory: Egocentric 3D Control from Pixels at 100000 FPS with Asynchronous Reinforcement Learning [Электронный ресурс]. 2020. URL: <https://arxiv.org/abs/2006.11751>.
2. Kempka M. и др. ViZDoom: A Doom-based AI Research Platform for Visual Reinforcement Learning [Электронный ресурс]. 2016. URL: <https://arxiv.org/abs/1605.02097>.